

Aprendizaje no-supervisado

Segmentación de mercado

Una reconocida empresa de supermercados desea desarrollar una campaña de marketing dirigida a sus clientes, con el objetivo de incrementar las ventas y mejorar la fidelización. Para tomar decisiones más efectivas, el equipo de analítica ha recolectado información detallada sobre el comportamiento de compra, los canales utilizados, la respuesta a campañas anteriores y algunas características demográficas de los clientes. Los datos están disponibles en [1]. Como parte del equipo de analítica de datos, su misión será aplicar técnicas de segmentación de mercado mediante algoritmos de agrupamiento. El objetivo es identificar grupos de clientes con comportamientos similares, generar perfiles claros para cada segmento y brindar recomendaciones que puedan ser utilizadas en futuras estrategias comerciales y de marketing personalizado.

Para esta tarea tenga en cuenta los siguientes pasos:

- Realice el proceso de limpieza de datos según lo considere necesario. Para esto tenga en cuenta:
 - Revise la información contenida en cada columna. Para esto se recomienda tener en cuenta el diccionario de datos presentado al final del documento.
 - Elimine columnas irrelevantes para el análisis,
 - Trate los valores faltantes en las columnas que lo requieran
 - Corrija o estandarice los valores para que sean coherentes y útiles para el análisis. Preste especial atención a problemas de valores redundantes en columnas como *Education* y *Marital_Status*
- Realice un proceso de ingeniería de características para generar nuevas columnas. Por ejemplo cree la columna:
 - *Age* a partir del año de nacimiento
 - *Total_spent* sumando todos los valores de las columnas que representan compras (*MntWines*, *MntFruits*, etc.)
 - *Children* que combine la información disponible en las columnas *Kidhome* y *Teenhome*
 - *Costumer_Tenure* como el número de días desde la vinculación del cliente. Considere la información en la columna *Dt_Customer*
 - *Campaign_Accepted_Total* como la suma de los valores de las columnas *AcceptedCmp1* a *AcceptedCmp5*
 - Considere si puede generar alguna otra columna que sea relevante para el análisis
- Seleccione las características que, a su juicio, mejor representen diferencias significativas entre los clientes
- Realice las transformaciones necesarias (por ejemplo, escalado, codificación de variables categóricas) e incorpore todo el proceso en un pipeline de preprocesamiento
- Aplique el algoritmo de k-Means para determinar el número óptimo de grupos. Para esto:
 - Agregue este modelo al pipeline generado en el punto anterior.
 - Determine el número de clústeres utilizando gráfica de codo, y el coeficiente y el diagrama de silueta.
- Realice el perfilamiento de los clientes por segmento. Para esto considere características distintivas como edad ingresos, número de hijos, gasto total etc. A partir de esto realice un análisis exploratorio para comparara estas características en cada segmento
- De un nombre a cada segmento de forma representativa, por ejemplo. “Clientes jóvenes con alto gasto”, “Familias con gasto moderado” “Clientes inactivos con bajo ingreso” etc.
- Genere una presentación de 3 o 4 diapositivas presentando los resultados del análisis

Para tener en cuenta

- Los ejercicios deben entregarse en un notebook.

- El proceso de preprocesamiento debe ser documentado en cada etapa. Esto será tenido en cuenta durante la calificación

Origen de datos

[1] https://raw.githubusercontent.com/jpospinalo/MachineLearning/refs/heads/main/k-means/marketing_campaign.csv

Diccionario de datos:

Columna	Descripción
ID	Identificador único del cliente.
Year_Birth	Año de nacimiento del cliente.
Education	Nivel educativo del cliente (e.g., Basic, Graduation, Master, PhD).
Marital_Status	Estado civil del cliente (e.g., Married, Single, Together, Widow, etc.).
Income	Ingreso anual del cliente en dólares.
Kidhome	Número de niños que viven en el hogar del cliente.
Teenhome	Número de adolescentes que viven en el hogar del cliente.
Dt_Customer	Fecha en la que el cliente fue registrado en el sistema.
Recency	Número de días desde la última compra.
MntWines	Monto gastado en vinos en los últimos 2 años.
MntFruits	Monto gastado en frutas en los últimos 2 años.
MntMeatProducts	Monto gastado en productos cárnicos en los últimos 2 años.
MntFishProducts	Monto gastado en pescados y mariscos en los últimos 2 años.
MntSweetProducts	Monto gastado en dulces en los últimos 2 años.
MntGoldProds	Monto gastado en productos de oro (regalos, joyas, etc.) en los últimos 2 años.
NumDealsPurchases	Número de compras realizadas con descuento.
NumWebPurchases	Número de compras realizadas a través de la web.
NumCatalogPurchases	Número de compras realizadas por catálogo.
NumStorePurchases	Número de compras realizadas en tiendas físicas.
NumWebVisitsMonth	Número de visitas al sitio web en el último mes.
AcceptedCmp1	Indicador (0 o 1) de aceptación de la primera campaña promocional.
AcceptedCmp2	Indicador de aceptación de la segunda campaña promocional.
AcceptedCmp3	Indicador de aceptación de la tercera campaña promocional.
AcceptedCmp4	Indicador de aceptación de la cuarta campaña promocional.
AcceptedCmp5	Indicador de aceptación de la quinta campaña promocional.
Response	Indicador de aceptación de la campaña promocional más reciente.
Complain	Indicador de si el cliente ha presentado alguna queja (1 = sí, 0 = no).
Z_CostContact	Valor constante sin variación (posiblemente un campo técnico del sistema).
Z_Revenue	Valor constante sin variación (posiblemente un campo técnico del sistema).