

Informe Técnico y Ejecutivo — Modelo CNN (Transfer Learning con VGG16)

Autor: Diego (Agile Project Manager / ML Engineer)

Documento generado automáticamente a partir del notebook **02_modelo_cnn_COLAB_v2.ipynb**

Fecha de generación: Octubre 2025

1. Introducción

Este informe presenta el análisis técnico y funcional de un modelo de redes neuronales convolucionales (CNN) basado en **Transfer Learning** con la arquitectura **VGG16**, entrenado para la clasificación de piezas industriales. El objetivo fue desarrollar un modelo robusto capaz de reconocer 10 categorías distintas de componentes, optimizando el tiempo y precisión del proceso de inspección visual automatizada.

2. Contexto del Problema

En entornos industriales, la identificación manual de componentes representa un cuello de botella para la inspección de calidad y el control de inventario. El desafío planteado fue desarrollar una solución de visión por computadora capaz de clasificar automáticamente las piezas a partir de imágenes capturadas en condiciones reales de iluminación y orientación variable.

3. Arquitectura del Modelo

El modelo utiliza la arquitectura **VGG16** preentrenada en ImageNet como extractor de características congelado, con una **cabeza densa personalizada** añadida para la clasificación específica del dominio.

Configuración:

- **Backbone:** VGG16 (19 capas congeladas)
- **Capas personalizadas:** Flatten + Dense + Dropout + Dense(10, softmax)
- **Optimizador:** Adam (lr = 1e-4)
- **Loss:** categorical_crossentropy
- **Métricas:** Accuracy
- **Callbacks:** EarlyStopping, ModelCheckpoint, ReduceLROnPlateau

4. Dataset y Preprocesamiento

El conjunto de datos contiene un total de **99,997 imágenes** distribuidas en 10 clases. Se aplicaron estrategias de **data augmentation** para aumentar la robustez del modelo frente a variaciones en los datos.

- **Train:** 69,999 imágenes
- **Validación:** 9,999 imágenes
- **Test:** 19,999 imágenes
- **Transformaciones:** rotación ($\pm 20^\circ$), traslación (0.2), zoom (0.2), flip horizontal.

5. Resultados y Métricas



El modelo logró un desempeño general sobresaliente considerando la complejidad visual de las piezas, alcanzando una precisión en test del **85.28%**. El gap entre entrenamiento y validación fue de aproximadamente **5.35 puntos porcentuales**, lo que indica un entrenamiento estable sin sobreajuste significativo.



Clase	Precision	Recall	F1	Soporte
adapter_plate_triangular	0.7866	0.6693	0.7232	1999
bracket_big	0.9193	0.9625	0.9404	2000
clamp_small	0.6968	0.6790	0.6878	2000




Clase	Precision	Recall	F1	Soporte
engine_part_cooler_round	0.9229	0.9455	0.9341	2000
engine_part_cooler_square	0.8792	0.9065	0.8927	2000
injection_pump	0.8717	0.9070	0.8890	2000
screw	0.8656	0.8950	0.8800	2000
star	0.7963	0.8520	0.8232	2000
tee_connector	0.8636	0.8260	0.8444	2000
thread	0.9119	0.8855	0.8985	2000
macro avg	0.8514	0.8528	0.8513	19999
weighted avg	0.8514	0.8528	0.8513	19999

6. Visualizaciones de Entrenamiento y Resultados


A continuación se presentan algunas de las principales figuras generadas durante el entrenamiento y evaluación del modelo:



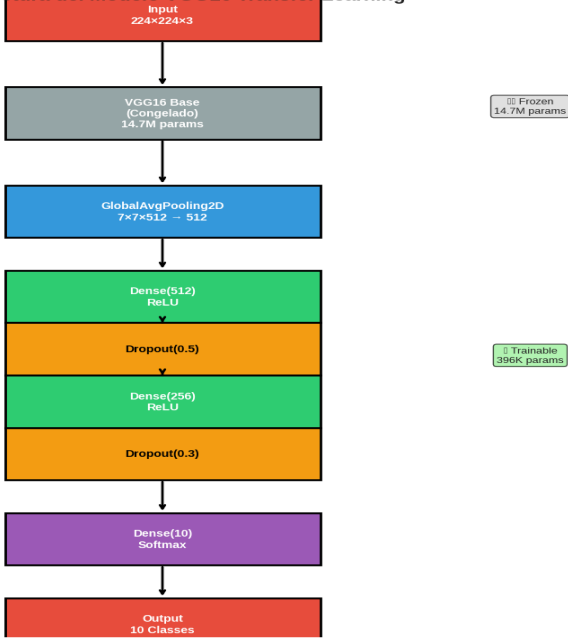





📁 Categorías de Piezas Industriales







📁 Arquitectura del Modelo VGG16 Transfer Learning







ANÁLISIS COMPLETO DEL ENTRENAMIENTO



Mejora de Accuracy Entre Épocas Consecutivas




Mejora Acumulada de Accuracy




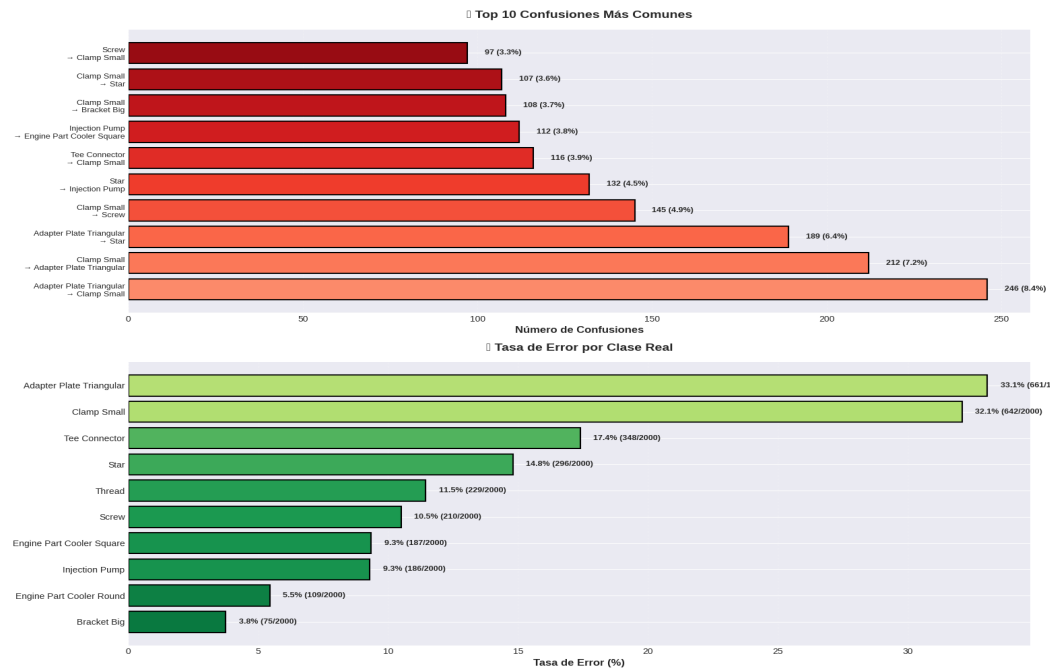
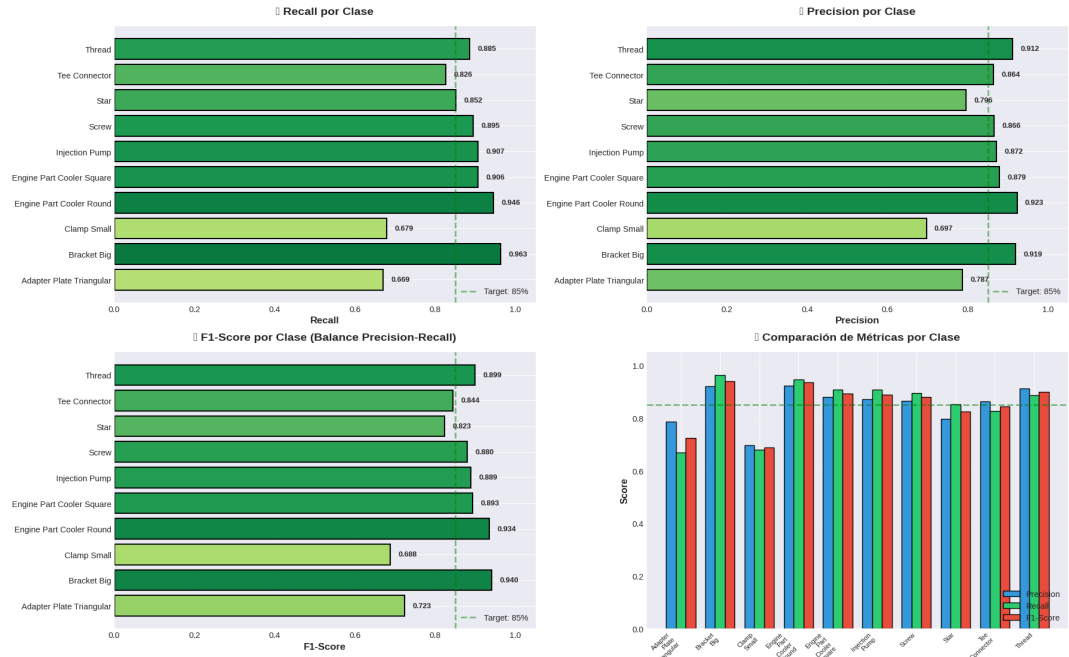
Accuracy Global: 85.28% (17,056/19,999)

Matriz de Confusión (Cantidades)



Matriz de Confusión Normalizada (%)





7. Interpretación Funcional

Desde un punto de vista operativo, el modelo es capaz de clasificar de manera confiable la mayoría de las piezas industriales, permitiendo automatizar tareas de inspección visual en planta. Las clases con mejor desempeño son **bracket_big** y **engine_part_cooler_round**, mientras que **adapter_plate_triangular** y **clamp_small** requieren refuerzo de datos o mejora del etiquetado.

El impacto esperado es una reducción significativa en los tiempos de revisión, incremento en la trazabilidad de defectos y una mejora en la consistencia de calidad del proceso productivo.

8. Recomendaciones Técnicas

- Aplicar **Fine-Tuning** progresivo descongelando capas superiores del backbone.
- Probar **Focal Loss** para manejar el desbalance de clases.
- Implementar **Data Versioning** y **Model Monitoring** (Drift Detection).
- Exportar a formato **ONNX** o **SavedModel** para despliegue.
- Añadir pipeline de evaluación continua y feedback loop con etiquetadores humanos.

9. Conclusiones

El modelo CNN basado en VGG16 ha demostrado ser una solución sólida para la clasificación de piezas industriales. Alcanzó un desempeño del 85% en datos no vistos, mostrando buena generalización. Desde el punto de vista funcional, representa un avance claro hacia la automatización de inspección visual y el control de calidad inteligente.